

**UNIVERSIDAD DE TARAPACÁ**  
**FACULTAD DE INGENIERÍA DEPARTAMENTO DE**  
**INGENIERÍA INDUSTRIAL Y DE SISTEMAS**



**ANTEPROYECTO**

**MODELO DE PREDICCIÓN PARA MATERIAL  
PARTICULADO PM<sub>2,5</sub> CON REDES  
NEURONALES.**

Alumno: Junior Barrera Diaz

Email: [junior.diaz.barrera@alumnos.uta.cl](mailto:junior.diaz.barrera@alumnos.uta.cl)

Teléfono: +56959414178

Profesor: Giuliani Coluccio Piñones

Fecha: 24-05-2024

## Índice

Capítulo 1 Justificación y Descripción General.....	2
Capítulo 2: Marco Teórico.....	6
1. Contaminación atmosférica.....	6
2. Material Particulado.....	8
3. Métodos de predicción.....	9
Capítulo 3: Objetivos.....	12
Objetivo General.....	12
Objetivos Específicos.....	12
Alcances y Limitaciones.....	12
Capítulo 4: Metodología.....	14
4.1 Proceso de Obtención y Preparación de Datos.....	14
4.1.1 Obtención de Datos.....	14
4.1.2 Acceso a la Base de Datos.....	14
4.1.3 Tipos de Datos Recopilados.....	14
4.1.4 Limpieza y Preprocesamiento de Datos.....	15
4.2 Elementos que componen una Red Neuronal.....	15
4.3 Tipos de Redes Neuronales Artificiales.....	18
4.4 Implementación de Redes Neuronales.....	19
4.4.1 Arquitecturas de Redes Neuronales.....	19
4.4.2 Entrenamiento del Modelo.....	19
4.5 Evaluación del Modelo.....	19
4.5.1 Métricas de Evaluación.....	19
4.6 Comparación de Resultados.....	20
4.6.1 Análisis Comparativo.....	20
4.6.2 Selección del Mejor Modelo.....	21

## Capítulo 1 Justificación y Descripción General.

El crecimiento económico y la globalización han traído consigo una serie de beneficios significativos, pero al mismo tiempo han dado origen a nuevos riesgos, especialmente en lo que respecta al medio ambiente y la salud pública (Marcos, 2005). Una de las preocupaciones principales es el impacto de los riesgos ambientales en la salud de la población. Entre el 25% y el 33% de la morbilidad total en países industrializados puede atribuirse a factores ambientales, aunque los niños menores de 5 años representan solo el 12% de la población, quienes soportan aproximadamente el 43% de la carga total de enfermedades relacionadas con factores ambientales (Smith et al., 1999).

Las ciudades de los países en desarrollo tienen niveles de contaminación más altos que las ciudades de los países más ricos, a pesar del mayor uso del transporte público por parte de sus residentes. Esto se debe a que estas ciudades no cuentan con la infraestructura necesaria para llevar combustibles limpios a los hogares para cocinar y calentarse, lo que resulta en un mayor uso de carbón sólido y biocombustibles. Además, estas ciudades contienen vehículos más antiguos con mayores emisiones de escape y carreteras sin pavimentar o en mal estado que suspenden polvo (Chow et al., 2004). Según la Agenda de Protección Ambiental de Estados Unidos (EPA) los vehículos y motores no certificados pueden emitir un 30% más de contaminantes del aire nocivos que lo que permiten los estándares, o incluso por encima de esta cifra (EPA, 2016).

El material particulado es una mezcla compleja de partículas sólidas y líquidas suspendidas en el aire, es habitual dividirlo en fracciones según el tamaño de las partículas con un diámetro menor a 10 micrómetros ( $\mu\text{m}$ ),

denominadas PM10, y las partículas más finas con un diámetro menor a 2,5  $\mu\text{m}$ , conocidas como PM2,5 (Suárez et al., 2017).

La Organización Mundial de la Salud (OMS) ha revelado que nueve de cada diez personas en todo el mundo respiran aire contaminado, principalmente debido al material particulado en suspensión. Dicho tipo de contaminación tiene consecuencias graves para la salud, siete millones de personas mueren cada año por la exposición a las partículas finas presentes en el aire contaminado. Estas partículas pueden penetrar profundamente en los pulmones y el sistema cardiovascular (WHO, 2018).

Éstos problemas respiratorios se ven exacerbados por los principales componentes de la contaminación del aire como material particulado fino (PM2,5), material particulado respirable (PM10), dióxido de nitrógeno ( $\text{NO}_2$ ), Ozono ( $\text{O}_3$ ), monóxido de carbono ( $\text{CO}$ ) y óxidos de azufre ( $\text{SO}_2$ ), los cuales pueden irritar las vías respiratorias, provocar dificultades respiratorias, asma, enfermedad pulmonar obstructiva crónica (EPOC), infecciones respiratorias, cáncer de pulmón y enfermedades cardíacas (Redlich et al., 2023). Además, según Anderson, et al. (2012), el material particulado, especialmente el PM2,5, es de particular interés debido a su impacto significativo en la salud humana, pudiendo ocasionar muertes prematuras a través de mecanismos inflamatorios, activación directa e indirecta de la coagulación y translocación directa al sistema circulatorio. El MP2,5 se ha vuelto de importante interés, debido al impacto negativo que provoca en la salud de las personas.

En Chile, este problema adquiere una relevancia particular según Hartinger et al. (2023), es uno de los países con mayor tasa de mortalidad prematura atribuible a la exposición a la contaminación del aire en sudamérica, las principales fuentes de contaminación son el medio de

transporte, las actividades industriales y la calefacción de las viviendas mediante combustión de leña.

Según el Sexto Reporte del Ministerio del Medio Ambiente (2021), las ciudades de Coyhaique, en la Región de Aysén, y Padre las Casas, en la Región de La Araucanía, sobresalen con altas concentraciones de material particulado fino. Durante un promedio trianual, ambas ciudades excedieron el valor normalmente aceptado de 20 microgramos por metro cúbico para la concentración de este material.

De la Tabla I, las ciudades de Chile como Padre las Casas, que conforman parte del área metropolitana de Temuco, continúan experimentando altas concentraciones de material particulado fino a lo largo del tiempo. De igual manera, Coyhaique enfrenta desafíos similares con la contaminación atmosférica.

Tabla I Número de Episodios Material particulado MP2,5, año 2023.

	Sobre_Norma	Alerta	Preemergencia	Emergencia	Total_Episodios
Santiago	59	18	2	0	20
Rancagua	58	18	4	1	23
Curicó	44	16	5	1	22
Talca	56	29	12	2	43
Linares	49	27	14	5	46
Cauquenes	14	4	3	1	8
San Carlos	49	19	21	7	47
Chillan	57	28	21	8	57
Los Ángeles	50	22	20	7	49
Concepción	53	12	7	5	24
Caranilahue	31	12	5	2	19
<b>Temuco</b>	<b>72</b>	<b>29</b>	<b>30</b>	<b>11</b>	<b>70</b>
Valdivia	43	21	2	0	23
La Unión	27	8	2	0	10
Osorno	64	24	31	5	60
Puerto Montt	62	26	26	14	66
Aysén	17	5	0	0	5
<b>Coyhaique</b>	<b>97</b>	<b>23</b>	<b>32</b>	<b>19</b>	<b>74</b>

**Nota:** Número de episodios de material particulado en diferentes ciudades en Chile. **CITA:** (MMA,2023).

Según el estudio realizado por Marcos Acuña (2015), se investigó la relación entre la contaminación del aire por MP10 y la salud de la población de Coyhaique, encontrándose un aumento estacional en consultas médicas y hospitalizaciones por enfermedades respiratorias durante los meses fríos, con los grupos de edad extremos siendo los más afectados. Sin embargo, las limitaciones del estudio, como el tamaño reducido de la población expuesta y la falta de datos sobre MP2,5, plantean desafíos para establecer una asociación precisa entre el material particulado y las enfermedades. El principal origen del material particulado en el sur de Chile está vinculado al uso de la leña para calefacción y cocción de alimentos, lo cual genera problemas ambientales en ciudades como Osorno, Temuco y Valdivia (Schueftan et al., 2016) la contaminación del aire es un problema ambiental que se ha vuelto crónico para estas ciudades, y que vuelve a aparecer cada invierno.

Por todo lo mencionado anteriormente es necesario la creación de un modelo predictivo ya que es fundamental para minimizar el daño causado por la contaminación en la salud humana, especialmente en ciudades chilenas con altas concentraciones de material particulado. Este modelo proporcionará a los profesionales de la salud y a los responsables políticos, información anticipada sobre los posibles riesgos para la salud asociados con niveles específicos de contaminación por PM2,5. Al anticipar estos riesgos, se les permitiría implementar medidas preventivas y de mitigación de manera más efectiva, tanto a corto como a largo plazo. Estos datos, fundamentales para la toma de decisiones informadas, estarán disponibles en el sitio oficial del Ministerio del Medio Ambiente a través del Sistema de Información Nacional de Calidad del Aire (SINCA). Lo que a su vez ayudaría a proteger la salud pública y a reducir el impacto negativo en la vida de la población.

## Capítulo 2: Marco Teórico

La contaminación atmosférica es un desafío global que trasciende fronteras y afecta de manera significativa la salud y calidad de vida de millones de personas en todo el mundo. Desde las principales ciudades hasta las regiones rurales, sus efectos se hacen presente, generando preocupación tanto a nivel local como internacional. En este contexto, Chile no es ajeno a esta realidad ya que, enfrentan niveles preocupantes de contaminación, lo que demanda la implementación de medidas efectivas y una comprensión profunda de las causas y consecuencias de este fenómeno.

### 1. Contaminación atmosférica

La contaminación atmosférica se define como la presencia de sustancias químicas y partículas en la atmósfera alterando su composición y suponiendo un riesgo para la salud de las personas y de los demás seres vivos (Díaz et al., 2014). Históricamente, ha existido contaminación atmosférica de origen natural, resultado de fenómenos como erupciones volcánicas, incendios forestales, tormentas de arena, descomposición de la materia orgánica y liberación de polen. Sin embargo, es a partir del descubrimiento del fuego por el hombre cuando surge la contaminación atmosférica antropogénica (Aránguez et al., 1999). Ello constituye a un problema ambiental por cuanto a la acción antrópica generando un efecto sobre un componente ambiental (aire) y el deterioro de éste afecta la supervivencia y calidad de vida del hombre (Barrios Casas et al., 2004).

La contaminación atmosférica se ha convertido en uno de los principales desafíos de salud pública que aquejan en entornos urbanos, afectando tanto a países desarrollados como en vías de desarrollo (Matus &

lucero, 2002). Los distintos contaminantes presentes en la atmósfera se manifiestan a través de pequeñas partículas o productos gaseosos secundarios, que pueden representar riesgos, daños o molestias para las personas, plantas y animales expuestos a dicho ambiente (IDEAM, 2024).

Los contaminantes del aire más comunes, según la OMS, incluyen el Material Particulado, Monóxido de Carbono, Ozono, Dióxido de Nitrógeno y Dióxido de Azufre, todos estos pueden tener diferentes efectos en la salud humana, desde irritación de las vías respiratorias hasta enfermedades cardiovasculares y cáncer de pulmón (WHO, 2022). Es importante destacar que, debido a las bajas temperaturas en invierno, junto con las condiciones climáticas y geográficas, hacen que la calefacción sea un servicio energético crucial para preservar la salud y la calidad de vida de la población durante los meses fríos (Jorquera et al., 2019). Sin embargo, el uso intensivo de sistemas de calefacción puede aumentar las emisiones de contaminantes atmosféricos, lo que empeora la calidad del aire. Este ciclo plantea un desafío para la salud pública, puesto que, aunque la calefacción es esencial para combatir el frío y prevenir enfermedades relacionadas con las bajas temperaturas, la contaminación del aire resultante puede agravar problemas respiratorios y otras condiciones de salud (Encinas et al., 2020).

El estudio realizado por Celis et al. (2007) destaca que la contaminación atmosférica en Chile, presenta un patrón cíclico durante las estaciones frías, principalmente debido al uso extendido de la madera como combustible para calefacción residencial en zonas urbanas. Esta práctica genera una densa nube de humo que afecta la calidad del aire, siendo el material particulado fino el principal contaminante identificado. Estos hallazgos se alinean con la investigación de Sandoval et al. (2019), que revela los efectos perjudiciales para la salud asociados con la exposición a



contaminantes atmosféricos, especialmente aquellos derivados de incendios forestales, donde el material particulado fino se identifica como el contaminante atmosférico predominante.

## 2. Material Particulado.

El material particulado definido por Arciniégas (2011), consiste en un conjunto de partículas sólidas y líquidas que son emitidas directamente al aire. A diferencia de otros contaminantes, el material particulado no sedimenta en períodos cortos, sino que permanece suspendido en el aire debido a su tamaño y densidad.

Este se encuentra dividido en dos grupos principales de acuerdo a su tamaño PM<sub>10</sub> y PM<sub>2.5</sub> (Colombia et al., 2010), los diferentes elementos presentes en el material particulado pueden estar asociados con materia mineral, compuestos de azufre, compuestos de nitrógeno y compuestos de carbono generados principalmente por las actividades antropogénicas y tráfico vehicular (Chiluiza, 2018).

En las últimas décadas, se ha observado una clara relación entre la contaminación atmosférica por partículas y el incremento tanto en la mortalidad como en la morbilidad asociadas a enfermedades respiratorias y cardiovasculares. Pequeños aumentos en la concentración de partículas se han relacionado con un mayor riesgo de enfermedades como la coronariopatía, el infarto de miocardio, la hipertensión arterial, el accidente cerebrovascular y las arritmias cardíacas (Román et al., 2004).

Entendiendo la gravedad del impacto del material particulado, se implementan diversas estrategias para reducir su efecto en la población. Una

de ellas es el desarrollo y la aplicación de diferentes metodologías estadísticas para predecir las concentraciones de material particulado.

### 3. Métodos de predicción

La evaluación continua de la calidad del aire y la exposición a los contaminantes atmosféricos, junto con el control regular, es crucial para tomar decisiones informadas y desarrollar estrategias efectivas de control de la contaminación (Guerreiro et al., 2014). En consecuencia, se ha observado un crecimiento significativo en la investigación y los esfuerzos destinados a comprender mejor este desafío ambiental y mitigar sus impactos adversos en la salud humana y el medio ambiente. Durante los últimos años, numerosos estudios han contribuido al avance del campo de la calidad del aire, abordando diversas facetas de esta problemática. Entre ellos, destacan investigaciones que han explorado la aplicación de modelos de predicción para estimar y pronosticar los niveles de contaminantes atmosféricos.

Un estudio realizado en Perú por Zare & Edó, (2015), analizó los datos de monitoreo de material particulado (PM<sub>2.5</sub>) en la ciudad de Lima utilizando el modelo de Holt-Winters y el análisis estadístico propuesto por Bermúdez et al. (2007). Además, se aplicó el modelo ARIMA para comparar su desempeño con los otros métodos; los pronósticos indican una tendencia negativa en los niveles de PM<sub>2.5</sub> para el próximo año. No obstante, los intervalos de predicción al 80% y 95% mostraron la posibilidad de valores negativos, lo que requirió la transformación de los datos a logaritmos para evitar valores por debajo de cero. Las condiciones iniciales estimadas incluyeron un nivel inicial de 4.307, una tendencia negativa de -0.023 y una componente estacional aditiva. Comparado con métodos automáticos, el

modelo de Bermúdez et al. (2007) mostró resultados similares en términos de bondad de ajuste, pero con diferentes parámetros de suavizado.

De manera similar, otro estudio realizado en Perú por Rojas & Medina, (2022), evaluó el desempeño de las Redes Neuronales Artificiales (RNA) para pronosticar las concentraciones de PM<sub>10</sub> en el aire, específicamente en el distrito de Lima. Utilizando datos de contaminantes atmosféricos y variables meteorológicas de la Estación de Monitoreo de la Calidad del Aire "ATE" junto con datos simulados del modelo WRF-CHEM, se desarrollaron diversas arquitecturas de RNA. Estas arquitecturas fueron sometidas a procesos de entrenamiento y validación, evaluándose su desempeño mediante el Error Cuadrático Medio (ECM), la precisión (BIAS) y el coeficiente de determinación (R<sup>2</sup>). La arquitectura óptima contó con 19 neuronas en la capa oculta y utilizó una función de activación sigmoideal para la capa oculta y una lineal para la capa de salida. Mostró un ECM de 0,0230, un BIAS de 0,5308 y un R<sup>2</sup> de 0,823, además, se observó que las RNA lograron predicciones para 1, 3 y 6 horas de antelación. Específicamente, con 1 hora de antelación, el modelo obtuvo un R<sup>2</sup> de 0,823, un ECM de 0,0230 y un BIAS de 0,5308. A medida que se aumentaba el horizonte de predicción a 3 y 6 horas, la precisión disminuye ligeramente, con valores de R<sup>2</sup> de 0,78 y 0,812, ECM de 0,0265 y 0,0345, y BIAS de 0,6997 y 1,1932.

Asimismo, un estudio realizado en España por Basurko et al., (2006), analizó las variables meteorológicas en especial los niveles de ozono basado en el uso de redes neuronales; el modelo de predicción muestra un buen ajuste para prever niveles de ozono hasta ocho horas en el futuro. Los indicadores de precisión revelan que el Error Cuadrático Medio Normalizado (NMSE) se encuentra entre 0.0007 y 0.0138, indicando una baja discrepancia entre las predicciones y los valores reales. Además, el

Coeficiente de Correlación varía entre 0.9360 y 0.9969, lo que sugiere una fuerte relación entre las predicciones y los datos observados. El Factor de Dos muestra (FA2) que, en el peor de los casos, el 99.01% de las predicciones a ocho horas vista están dentro del intervalo  $[0.5, 2]$ , y en el mejor de los casos, el 99.78% de las predicciones a una hora vista están en el mismo intervalo. Aunque el sesgo fraccional y la varianza fraccional son relativamente pequeños, aumentan a medida que se prolonga el horizonte de predicción.

En México, Guzmán et al., (2017) desarrolló una metodología computacional basada en Redes Neuronales Artificiales (RNA) para estimar el índice de concentración de PM<sub>10</sub> y PM<sub>2.5</sub> en aire de la ciudad de San Francisco de Campeche. Usando una arquitectura de RNA de tres capas; utilizando una base de datos experimental compuesta por días de la semana, hora del día, temperatura ambiente, presión atmosférica, velocidad y dirección del viento, humedad relativa y radiación solar. La mejor arquitectura de RNA, compuesta por 30 neuronas en capa oculta, se obtuvo utilizando el algoritmo de optimización de Levenberg-Marquardt (LM), funciones de transferencia sigmoidea logarítmica y lineal. Los resultados del modelo generan predicciones con un coeficiente de determinación ( $R^2$ ) del 93,01% y del 90,10% para PM<sub>2,5</sub> y PM<sub>10</sub>.

En relación a lo anterior, los métodos utilizados y los resultados obtenidos en diversos estudios han demostrado consistentemente la eficacia de las Redes Neuronales Artificiales (RNA) en la predicción de niveles de contaminantes a corto y largo plazo. Destacando el alto rendimiento de las RNA en la predicción de concentraciones de PM<sub>10</sub>, logrando una precisión significativa en sus estimaciones (Rojas & Medina, 2022). También, Guzmán et al. (2017) evidenció la precisión superior de las RNA en la estimación de

PM2.5 y PM10. Estos estudios muestran que las RNA son especialmente efectivas en situaciones donde las relaciones entre variables son altamente no lineales y multifactoriales. Por lo tanto, se propone su uso como un método fundamental para minimizar el daño causado por la contaminación en la salud de la comunidad.

## Capítulo 3: Objetivos

### Objetivo General

Desarrollar un modelo de predicción para el material particulado PM2.5 utilizando diferentes arquitecturas de redes neuronales.

### Objetivos Específicos

1. Obtener y recopilar datos sobre el PM2.5 en las ciudades con altos niveles de contaminantes como Coyhaique y Padre las Casas.
2. Implementar y entrenar diversas arquitecturas de redes neuronales para la predicción a corto plazo de niveles de PM2.5.
3. Evaluar el rendimiento de cada arquitectura de red neuronal utilizando diferentes métricas.
4. Comparar los resultados de las diferentes arquitecturas para identificar la más efectiva.

### Alcances y Limitaciones

La propuesta para la creación de un modelo predictivo de la contaminación del aire se enfoca exclusivamente en Chile, con especial atención a las ciudades de Coyhaique y Padre Las Casas, conocidas por sus altos niveles de contaminación. El modelo desarrollado tiene el potencial de

ser aplicado en todas las ciudades de Chile que cuenten con estaciones de monitoreo de la calidad del aire registradas por el Ministerio del Medio Ambiente, lo que amplía su aplicabilidad a nivel nacional.

No obstante, existen varias limitaciones que deben considerarse. En cuanto a las limitaciones geográficas, el modelo se desarrollará y validará únicamente con datos de ciudades chilenas, específicamente Coyhaique y Padre Las Casas, sin considerar datos de ciudades de otros países. Desde una perspectiva tecnológica, el desarrollo y la implementación del modelo se realizarán utilizando el lenguaje de programación Jupyter Notebook, lo que implica que su aplicabilidad en otros entornos de programación requerirá la traducción y adaptación del código. Además, la variabilidad estacional es una consideración importante, ya que los niveles de PM<sub>2.5</sub> pueden verse afectados por factores estacionales como cambios en las condiciones meteorológicas lo cual podría complicar las predicciones. Por último, factores externos como incendios forestales, erupciones volcánicas u otras fuentes de contaminación pueden introducir ruido en los datos y afectar la precisión del modelo.

## Capítulo 4: Metodología

Los modelos predictivos son herramientas en el campo del aprendizaje automático que se utilizan para realizar predicciones o estimaciones sobre datos futuros o desconocidos, basándose en patrones identificados en datos históricos. Dentro del estudio de las predicciones, las redes neuronales se destacan por su capacidad para pronosticar datos de series de tiempo y otras aplicaciones complejas.

### 4.1 Proceso de Obtención y Preparación de Datos

#### 4.1.1 Obtención de Datos

Para el desarrollo del modelo predictivo de la contaminación del aire, se obtendrán los datos del Sistema de Información Nacional de Calidad del Aire (SINCA), una plataforma oficial que proporciona información detallada sobre la calidad del aire en diversas ciudades de Chile.

#### 4.1.2 Acceso a la Base de Datos

Los datos se obtendrán mediante acceso a la base de datos pública del SINCA, descargando los registros disponibles para las estaciones de monitoreo ubicadas en Coyhaique y Padre Las Casas, los datos utilizados abarcarán desde el 1 de enero de 2016 hasta marzo de 2023.

#### 4.1.3 Tipos de Datos Recopilados

- Concentraciones de PM2.5: Este es el principal contaminante que se analizará y predecirá. Los registros validados de PM2.5 son fundamentales para la creación del modelo.
- Variables Meteorológicas: Se recopilarán datos sobre variables meteorológicas que influyen en los niveles de contaminación del aire,

tal como la presión atmosférica (hPa), humedad relativa (%), temperatura (°C) y velocidad del viento (m/s).

#### 4.1.4 Limpieza y Preprocesamiento de Datos

Durante la fase de limpieza y preprocesamiento de datos, se llevarán a cabo varias técnicas para asegurar la calidad y coherencia de los datos recopilados:

- Tratamiento de Datos Faltantes: Se implementará un procedimiento para identificar y tratar los datos faltantes. En el caso de que se encuentren valores ausentes (NA), se aplicará interpolación simple por promedio. Este método ayudará a mantener la integridad de los registros temporales y asegurará que los conjuntos de datos estén completos.
- Gráficos Explicativos: Se incluirá un gráfico que ilustra la distribución de los datos después de la limpieza y procesamiento, facilitando la comprensión de cómo los datos han sido preparados para el modelado.
- División de los Datos: Se adoptará un enfoque para conservar los patrones estacionales y garantizar la representatividad de los conjuntos de entrenamiento y prueba. El 80% de los datos se destinará al conjunto de entrenamiento, utilizado para desarrollar y ajustar los modelos predictivos. El restante 20% se reservará para el conjunto de prueba, donde se evaluará la precisión y el rendimiento de los modelos en datos no vistos durante el entrenamiento.


#### 4.2 Elementos que componen una Red Neuronal.

De la Figura N°1, una red neuronal está constituida por neuronas interconectadas y organizadas en tres capas principales: la capa de entrada,



la capa oculta y la capa de salida. Los datos ingresan a través de la capa de entrada, pasan a través de la capa oculta y finalmente salen por la capa de salida.

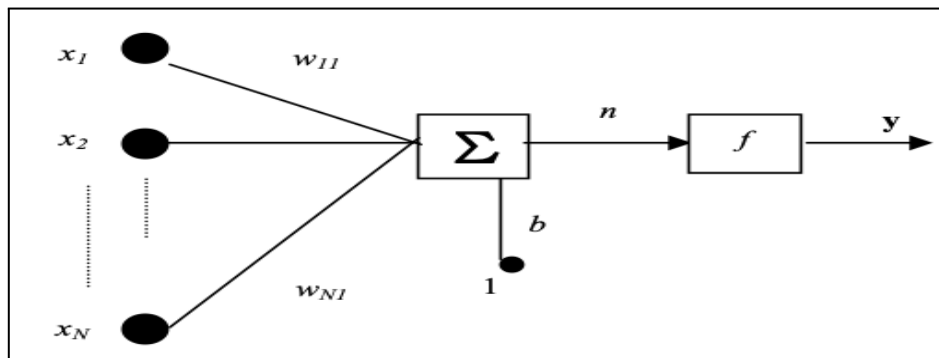
Figura N°1: Esquema de una Red Neuronal.



**Nota:** Esquema de una red neuronal completamente conectada. **CITA:** (Ruiz et al., 2001).

De la Figura N°2, según Basurko et al.,(2006), “los valores  $x_j$  son las entradas a la red neuronal, y los valores  $w_{kj}$  son los pesos sinápticos que conectan la  $j$ -ésima entrada con la  $k$ -ésima neurona. El valor  $b$ , que actúa como un umbral, puede considerarse un peso adicional. La función de activación  $f$  se aplica al valor procesado por la neurona. Finalmente, el valor  $y$  representa la salida de la neurona”.

Figura N°2: Neurona simple o perceptrón.



**Nota:** Esquema de una neurona simple o perceptrón. **CITA:** (Basurko et al.,2006)

Así mismo, en la Figura N°3, la expresión analítica de esta neurona describe cómo funciona una neurona en una red neuronal.

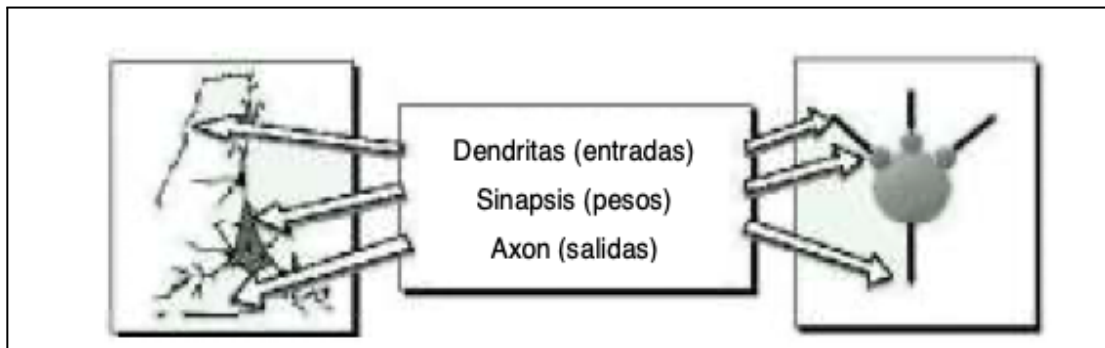
Figura N°3: Expresión Analítica

$$y = f(n) = f\left(\sum_{j=1}^N w_{kj} x_j + b\right) \quad (1)$$

**Nota:** Expresión matemática. **CITA:** (Basurko et al.,2006)

De la Figura N°4, una neurona biológica, recibe señales eléctricas, las procesa y envía impulsos eléctricos a otras neuronas. Las redes neuronales artificiales se inspiran en la estructura y el funcionamiento de las neuronas biológicas. Al igual que las neuronas en el cerebro, las neuronas artificiales pueden recibir y procesar información de manera eficiente, permitiendo que la red en su conjunto resuelva problemas complejos.

Figura N°4: Comparación entre neurona biológica y artificial.



**Nota:** Comparación entre una neurona biológica y una neurona artificial.

**CITA:** (Ruiz et al., 2001).

#### 4.3 Tipos de Redes Neuronales Artificiales

##### Redes Estáticas

Las redes estáticas se caracterizan por la capacidad de calcular sus salidas directamente a partir de las entradas mediante conexiones hacia adelante. Este tipo de redes incluyen el las redes feedforward (FNN) y perceptrón multicapa (MLP) la característica común de estas redes es que no poseen memoria; es decir, sólo son capaces de transformar un conjunto de entradas en un conjunto de salidas sin tener en cuenta estados anteriores (Centeno & Sevilla, 2019).

##### Redes Dinámicas

En contraste, las redes dinámicas tienen la capacidad de utilizar no sólo las entradas actuales, sino también las entradas, salidas o estados previos de la red. Esto introduce un elemento de memoria, permitiendo que las redes dinámicas establezcan relaciones entre las entradas y salidas

actuales y previas. Este tipo de redes incluyen el las redes recurrentes (RNN) y Long short-term memory (LSTM) (Centeno & Sevilla, 2019).

#### 4.4 Implementación de Redes Neuronales

##### 4.4.1 Arquitecturas de Redes Neuronales

Las redes neuronales que se implementarán son las siguientes, el perceptrón multicapa (MLP) y Long short-term memory (LSTM). La selección de estas arquitecturas se realizará mediante un proceso iterativo de prueba y error, donde se evaluarán diversas configuraciones de números de capas, número neuronal y función de activación.

##### 4.4.2 Entrenamiento del Modelo

Se utilizará un enfoque iterativo basado en prueba y error para optimizar los hiperparámetros clave de la red neuronal. Esto incluye ajustar la tasa de aprendizaje, el número de épocas y el tamaño del lote. Durante el proceso de entrenamiento, se evaluará el desempeño del modelo en un conjunto de validación después de cada época para ajustar los hiperparámetros.

#### 4.5 Evaluación del Modelo

##### 4.5.1 Métricas de Evaluación

Durante la evaluación del modelo, se utilizarán varias métricas para medir su rendimiento y precisión en función de cómo se ajustan las predicciones a los datos reales. Las métricas principales son:

- Error Cuadrático Medio (MSE): Esta métrica calcula el promedio de los cuadrados de los errores entre las predicciones del modelo y los valores reales.
- Coeficiente de Determinación ( $R^2$ ): Proporciona una medida de qué tan bien las predicciones del modelo se ajustan a los datos reales. Un valor de  $R^2$  más cercano a 1 indica un mejor ajuste del modelo a los datos observados.
- Mean Absolute Error (MAE): Esta métrica calcula el promedio de los valores absolutos de los errores entre las predicciones del modelo y los valores reales.
- Mean Absolute Percentage Error (MAPE): Calcula el promedio de los errores porcentuales absolutos entre las predicciones y los valores reales.

#### 4.6 Comparación de Resultados

##### 4.6.1 Análisis Comparativo

El proceso de comparación de las diferentes arquitecturas de redes neuronales se llevará a cabo utilizando conjuntos de datos de las ciudades de Coyhaique y Padre Las Casas. En Coyhaique, se evaluarán las diferentes arquitecturas de redes neuronales MLP y LSTM para determinar su rendimiento en términos de diversas métricas de evaluación. Este análisis permitirá identificar cuál de estas arquitecturas ofrece mayor precisión y mejor capacidad de generalización para los datos específicos de Coyhaique.

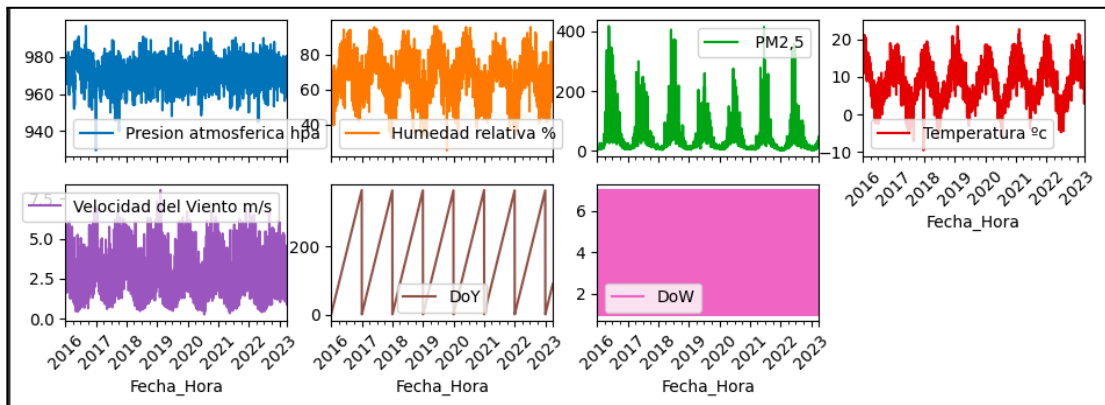
De manera similar, se realizará una comparación entre las arquitecturas MLP y LSTM utilizando datos de Padre Las Casas, lo que permitirá identificar cuál de las arquitecturas es más adecuada para los patrones específicos presentes de esta ciudad.

#### 4.6.2 Selección del Mejor Modelo

Se utilizará gráfico de líneas para visualizar las predicciones frente a los valores reales de PM2.5, así como el desempeño de las diferentes arquitecturas de redes neuronales artificiales (RNA). Este gráfico permitirá comparar de manera visual la precisión y la capacidad de cada modelo, facilitando la identificación de la arquitectura más adecuada para abordar los niveles de contaminación en distintas ciudades.


## Anexo

Figura N°5: Gráfico de presión atmosférica, humedad relativa, entre otros.




Fuente: Elaboración Propia.

Figura N°6: Evaluación del error porcentual.



Fuente: Elaboración Propia.

Figura N°7: Evaluación de Predicción vs Real .



Fuente: Elaboración Propia.



## Referencias

1. Chow, J., Watson, J., Shah, J., Kiang, C., Loh, C., Lev-On, M., Lents, J., Molina, M., & Molina, L. (2004). Megacities and Atmospheric Pollution. *Journal of the Air & Waste Management Association*, 54, 1226-1235. <https://doi.org/10.1080/10473289.2004.10470995>
2. Smith, K. R., Corvalán, C. F., & Kjellström, T. (1999). How Much Global Ill Health Is Attributable to Environmental Factors?: *Epidemiology*, 10(5), 573-584. <https://doi.org/10.1097/00001648-199909000-00027>
3. Anderson, J. O., Thundiyil, J. G., & Stolbach, A. (2012). Clearing the Air: A Review of the Effects of Particulate Matter Air Pollution on Human Health. *Journal of Medical Toxicology*, 8(2), 166-175. <https://doi.org/10.1007/s13181-011-0203-1>
4. WHO. (2018). Nueve de cada diez personas de todo el mundo respiran aire contaminado Sin embargo, cada vez hay más países que toman medidas. <https://www.who.int/es/news/item/02-05-2018-9-out-of-10-people-world-wide-breathe-polluted-air-but-more-countries-are-taking-action>
5. Marcos, V. (2005). La contaminación ambiental como factor determinante de la salud. *Revista Española de Salud Pública*, 79(2), 117–127. [https://scielo.isciii.es/scielo.php?script=sci\\_arttext&pid=S1135-57272005000200001](https://scielo.isciii.es/scielo.php?script=sci_arttext&pid=S1135-57272005000200001)
6. EPA. (2016). *Implementación de las leyes y normas sobre el aire* | US EPA. US EPA.

<https://espanol.epa.gov/espanol/implementacion-de-las-leyes-y-normas-sobre-el-aire>

7. Redlich, C. A., James, E. S., & Linde, B. (2023). Enfermedades relacionadas con la contaminación atmosférica. Manual MSD Versión Para Público General; Manuales MSD. <https://www.msdmanuals.com/es-cl/hogar/trastornos-del-pulm%C3%B3n-y-las-v%C3%ADas-respiratorias/enfermedades-pulmonares-ambientales-y-ocupacionales/enfermedades-relacionadas-con-la-contaminaci%C3%B3n-atmosf%C3%A9rica?autoredirectid=23364>
8. Hartinger, S. M., Yglesias-González, M., Blanco-Villafuerte, L., Palmeiro-Silva, Y. K., Lescano, A. G., Stewart-Ibarra, A., Rojas-Rueda, D., Melo, O., Takahashi, B., Buss, D., Callaghan, M., Chesini, F., Flores, E. C., Carolina Gil Posse, Gouveia, N., Slava Jankin, Zaray Miranda-Chacon, Nahid Mohajeri, Helo, J., & Ortiz, L. (2023). The 2022 South America report of The Lancet Countdown on health and climate change: trust the science. Now that we know, we must act. the Lancet Regional Health. Americas, 20, 100470–100470. <https://doi.org/10.1016/j.lana.2023.100470>
9. MMA (Ministerio del Medio Ambiente), 2021. Reporte del Estado del Medio Ambiente. [Mma.gob.cl.https://sinia.mma.gob.cl/estado-del-medio-ambiente/report-e-del-estado-del-medio-ambiente-2021/](https://sinia.mma.gob.cl/estado-del-medio-ambiente/report-e-del-estado-del-medio-ambiente-2021/)

10. MMA (Ministerio del Medio Ambiente), 2023. DEPARTAMENTO DE REDES DIVISIÓN DE CALIDAD DEL AIRE MINISTERIO DEL MEDIO AMBIENTE REPORTE MENSUAL EVOLUCIÓN DE EPISODIOS CRÍTICOS PARA MP2,5 Reporte septiembre 2023. <https://airechile.mma.gob.cl/download/Reporte-Mensual-MP25-Septiembre-2023.pdf>
11. Suárez, L., Tolentino, Á., Bendejú, Y., & Pomalaya, J. (2017). Caracterización química del material particulado atmosférico del centro urbano de Huancayo, Perú. *Revista de La Sociedad Química Del Perú*, 83(2), 187–199. [http://www.scielo.org.pe/scielo.php?pid=S1810-634X2017000200005&script=sci\\_arttext](http://www.scielo.org.pe/scielo.php?pid=S1810-634X2017000200005&script=sci_arttext)
12. Schueftan, A., Sommerhoff, J., & Alejandro Daniel Gonzalez. (2016). Firewood demand and energy policy in south-central Chile. *Energy Sustainable Development/Energy for Sustainable Development*, 33, 26–35. <https://doi.org/10.1016/j.esd.2016.04.004>
13. Encinas, F., Truffello, R., Urquiza, A., & Macarena Valdés Salgado. (2020). COVID-19, pobreza energética y contaminación: redefiniendo la vulnerabilidad en el centro-sur de Chile. ResearchGate; unknown. [https://www.researchgate.net/publication/341655323\\_COVID-19\\_pobreza\\_energetica\\_y\\_contaminacion\\_redefiniendo\\_la\\_vulnerabilidad\\_en\\_el\\_centro-sur\\_de\\_Chile?enrichId=rgreq-eedf60d47f24b6d6842e7d839](https://www.researchgate.net/publication/341655323_COVID-19_pobreza_energetica_y_contaminacion_redefiniendo_la_vulnerabilidad_en_el_centro-sur_de_Chile?enrichId=rgreq-eedf60d47f24b6d6842e7d839)

61c0aa2-XXX&enrichSource=Y292ZXJQYWdlOzM0MTY1NTMyMztB  
Uzo4OTU1NDgyOTkxNjE2MDNAMTU5MDUyNjc2MTIyMw%3D%3D&  
el=1\_x\_3&\_esc=publicationCoverPdf

14. Jorquera, C. A., Gallardo, R. C., Fuentes, A. C., Gómez, A. U., Vergara, J. M., & Argel, P. R. (2019). POBREZA ENERGÉTICA. [https://www.cr2.cl/wp-content/uploads/2020/01/policypaper\\_redpe20191128.pdf](https://www.cr2.cl/wp-content/uploads/2020/01/policypaper_redpe20191128.pdf)
15. Marcos, A. (2015). Impacto de la contaminación del aire por mp10 en la morbi-mortalidad por enfermedad respiratoria, cardiovascular y algunos cánceres en la población de Coyhaique, 2009-2014. [https://bibliodigital.saludpublica.uchile.cl/dspace/bitstream/handle/123456789/472/Tesis\\_Marco%20Acu%C3%B1a.pdf?sequence=1&isAllowed=y](https://bibliodigital.saludpublica.uchile.cl/dspace/bitstream/handle/123456789/472/Tesis_Marco%20Acu%C3%B1a.pdf?sequence=1&isAllowed=y)
16. IDEAM. (2024). CONTAMINACIÓN ATMOSFÉRICA - IDEAM. <http://www.ideam.gov.co/web/contaminacion-y-calidad-ambiental/contaminacion-atmosferica>
17. Matus, P., & Lucero, R. (2002). Norma primaria de calidad del aire. <https://revchilenfermrespir.cl/pdf/S0717-73482002000200006.pdf>
18. Díaz, G. O., Saboya, P. E. C., Goicochea, A. S., Tuesta, A. S. V., & Torres, D. A. (2014). CONTAMINACIÓN ATMOSFÉRICA. [https://d1wqtxts1xzle7.cloudfront.net/37420957/Contaminacion\\_atmosf](https://d1wqtxts1xzle7.cloudfront.net/37420957/Contaminacion_atmosf)

erica\_terminado-libre.pdf?1429992666=&response-content-disposition  
=inline%3B+filename%3DContaminacion\_atmosferica.pdf&Expires=17  
15452913&Signature=DkfGp9f6Flm5WrbAb-9gEXcSZmDzY8c2JRHO  
YqqmnvYccM9onBliXOARAecdSOGCiY24yylyLLmiy-CQmIC0bA-PI9u  
4LgGrnj7BQ63jfJmcYpL-BYMTJB~lu-KHRg0VT5roEHGB6t0kttSfFaP4  
CxKbVR3aXPkH9NxFPxTcGCYOSYhy6CYe4GI~WibIC0kvH4PdfjrnQ  
eVbdMAGgh304A0RGTKbKhzwnIK0VgVh-TMW53eXoITCp9WPajuPh  
BJDL95EBTJPyYXI7LpMbdKsuaaOBtN7OUO5WhIA0d79llePlrrGcsIN  
H2ko~1mGFHpCMDWQWJ~dMHuv0NShwT6CWg\_\_&Key-Pair-Id=A  
PKAJLOHF5GGSLRBV4ZA

19. Barrios Casas, S., Peña-Cortés, F., & Osses Bustingorry, S. (2004).  
EFFECTS FOR PARTICLES MATERIAL ATMOSPHERIC POLLUTION  
ON ACUTE RESPIRATORY DISEASES IN UNDER 5 YEARS OF  
AGE. Ciencia y enfermería, 10(2), 21-29.  
<https://doi.org/10.4067/S0717-95532004000200004>
20. WHO. (2022). Contaminación del aire ambiente (exterior). Who.int;  
World Health Organization: WHO.  
[https://www.who.int/es/news-room/fact-sheets/detail/ambient-\(outdoor\)-air-quality-and-health](https://www.who.int/es/news-room/fact-sheets/detail/ambient-(outdoor)-air-quality-and-health)
21. ARCINIÉGAS, C. A. (2011). DIAGNÓSTICO Y CONTROL DE  
MATERIAL PARTICULADO: PARTÍCULAS SUSPENDIDAS TOTALES

Y FRACCIÓN RESPIRABLE PM 10 \*

<http://www.scielo.org.co/pdf/luaz/n34/n34a12.pdf>

22. Aránguez, E., Ordóñez, J. M., Serrano, J., Aragonés, N., Fernández-Patier, R., Gandarillas, A., & Galán, I. (1999). Contaminantes atmosféricos y su vigilancia. *Revista Española de Salud Pública*, 73(2).

<https://doi.org/10.1590/S1135-57271999000200003>

23. Zare, E. G., & Edó, J. D. B. (2015). Análisis estadístico del modelo de Holt-Winters: Aplicación a la contaminación de aire por pm2.5 de Lima, Perú. *CONOCIMIENTO PARA EL DESARROLLO*, 6(2), Article 2. <https://revista.usanpedro.edu.pe/index.php/CPD/article/view/84>

24. Chiluiza, N. (2018). Evaluación de la Concentración de Material Particulado PM10 y PM2.5 en la Parroquia Belisario Quevedo de la Provincia de Cotopaxi en el periodo 2018 – 2019. *Utc.edu.ec*. <http://repositorio.utc.edu.ec/handle/27000/5248>

25. Colombia, Q., Parra, A., Vargas, Q., Juliana, M., Martínez, H., & Antonio, J. (2010). Bistua: *Revista de la Facultad de Ciencias Básicas*. <https://www.redalyc.org/pdf/903/90315226007.pdf>

26. Sandoval, B., Reyes, T., & Oyarzún, M. (2019). Mecanismos de los efectos nocivos para la salud de la contaminación atmosférica proveniente de incendios forestales. *Revista chilena de enfermedades*

respiratorias, 35(1), 49-57.

<https://doi.org/10.4067/S0717-73482019000100049>

27. Rojas , J. P., & Medina , E. A. (2022). PRONÓSTICO DE LAS CONCENTRACIONES DE MATERIAL PARTICULADO EN EL AIRE (PM10) UTILIZANDO REDES NEURONALES ARTIFICIALES: CASO ESTUDIO EN EL DISTRITO DE ATE, LIMA. *Revista de La Sociedad Química Del Perú*, 88(3). <https://doi.org/10.37761/rsqp.v88i3.402>
28. Guzmán, A., Tzuc, O., Isaías Pantí, Trujeque, J., Quintana, I., & Bassam, A. (2017). MODELADO DE PARTÍCULAS PM10 Y PM2.5 MEDIANTE REDES NEURONALES ARTIFICIALES SOBRE CLIMA TROPICAL DE SAN FRANCISCO DE CAMPECHE, MÉXICO. *Química Nova*. <https://doi.org/10.21577/0100-4042.20170115>
29. Lim, Y.-H., Josephine Funck Bilsteen, Laust Hvas Mortensen, Ranja, L., Zhang, J., Stéphane Tuffier, Brandt, J., Matthias Ketzel, Trine Flensburg-Madsen, Cathrine Lawaetz Wimmelmann, Gunhild Tidemann Okholm, Emilie Rune Hegelund, George Maria Napolitano, Zorana Jovanovic Andersen, & Loft, S. (2024). Lifetime exposure to air pollution and academic achievement: A nationwide cohort study in Denmark. *Environment International*, 185, 108500–108500. <https://doi.org/10.1016/j.envint.2024.108500>

30. Román, O., Prieto, J., & Mancilla, P. (2004). Contaminación atmosférica y daño cardiovascular. *Revista médica de Chile*, 132(6), 761-767. <https://doi.org/10.4067/S0034-98872004000600014>
31. Guerreiro, C. B. B., Foltescu, V., & de Leeuw, F. (2014). Air quality status and trends in Europe. *Atmospheric Environment*, 98, 376-384. <https://doi.org/10.1016/j.atmosenv.2014.09.017>
32. Basurko, E., Sanz, A., Barrón, L. J., & Albizu, M. (2006). Relevancia de las variables meteorológicas en el diseño de un modelo de predicción de los niveles de ozono, en tiempo real, basado en el uso de redes neuronales. *Aemet.es*. <https://repositorio.aemet.es/handle/20.500.11765/5205>
33. Ruiz, C. A., Basualdo, M. S., & Matich, D. J. (2001). *Redes Neuronales: Conceptos Básicos y Aplicaciones*. [https://d1wqtxts1xzle7.cloudfront.net/36957218/redesneuronales-libre.pdf?1426217818=&response-content-disposition=inline%3B+filename%3DRedes\\_Neuronales\\_Conceptos\\_Basicos\\_y\\_Apl.pdf&Expires=1717967194&Signature=KCEs9~s~OhuRUZOHCj6xa8aKXhLYK7azaOLH9QgdQVsaT6wZHNeBKe~hfZ-f7DbCynCi-xmqQ2U39m1EwNwEzQu2SscxfQRkjqrWlt7RXFyjL8tcT~tl0PtJVluGkMGn74e1BiLk89z6ZHbRY5JQNAfkuVTObbQDwdIKisLJMrwwiHDYZ8rDvy1dqqXKDmu9Z1BaSTKwkJZuAb5utLtWiSDoUoLe2XH6Hr2MrPrTj0G8OTfMouNYJ](https://d1wqtxts1xzle7.cloudfront.net/36957218/redesneuronales-libre.pdf?1426217818=&response-content-disposition=inline%3B+filename%3DRedes_Neuronales_Conceptos_Basicos_y_Apl.pdf&Expires=1717967194&Signature=KCEs9~s~OhuRUZOHCj6xa8aKXhLYK7azaOLH9QgdQVsaT6wZHNeBKe~hfZ-f7DbCynCi-xmqQ2U39m1EwNwEzQu2SscxfQRkjqrWlt7RXFyjL8tcT~tl0PtJVluGkMGn74e1BiLk89z6ZHbRY5JQNAfkuVTObbQDwdIKisLJMrwwiHDYZ8rDvy1dqqXKDmu9Z1BaSTKwkJZuAb5utLtWiSDoUoLe2XH6Hr2MrPrTj0G8OTfMouNYJ)



aoVgP2M~qlb~sa59HqPSuvxb7MG9W24P-r4qoU6kR5FN92HPqJCe9  
U6V6yPngT62YuiftMH5I32iMWkrfCmT9iT14txuvdKkw\_\_&Key-Pair-Id=  
APKAJLOHF5GGSLRBV4ZA

34. Centeno, A., & Sevilla, F. (2019). *DEEP LEARNING*.  
[https://idus.us.es/bitstream/handle/11441/90004/Centeno%20Franco%  
20Alba%20TFG.pdf](https://idus.us.es/bitstream/handle/11441/90004/Centeno%20Franco%20Alba%20TFG.pdf)